

ביקורת מחקרית של תוצאות Phase 6 בפרויקט PINO SPNO

ניתוח עצמאי של C1 מול FNO ושל זיהוי הרכיבים הקינטיים והמקומיים

1 באוקטובר 2026 · ניתוח תוצאות שמורות וקוד · ללא אימון חדש

A. Executive verdict

יש כאן תופעה מחקרית אמיתית, אך התוצאות אינן תומכות בטענה ש־C1 למד חוק קינטי הניתן להעברה לתדרים חדשים. C1/K0/L0 הוא מודל קומפקטי בעל מבנה גאומטרי ממש: הוא שומר מסה, הפיך וסימפלקטי על הרשת, ובתחום האימון הוא משיג דיוק תחרותי מול הבסיסים הגדולים. הממצא החיובי הברור ביותר מול baseline שאינו נכשל באופן קיצוני הוא עמידות לפוטנציאל בעל אורך קורלציה קצר: ב־G3-short שגיאת הצעד של C1 היא 0.05154% לעומת 0.22493% של A-wide, עם כ־436 פעמים פחות פרמטרים ממשיים. עם זאת, ב־G2 שגיאת rollout של C1 מגיעה לכ־66.7%, וב־G4 היא מגיעה לכ־60%–103%, כך ששימור המבנה אינו שקול לחיזוי שימושי מחוץ להתפלגות. בדיקות G5 והקצבים הישירים מראות קינטיקה נכונה בקירוב בתחום $k \leq 8$ ולאחריו רוויה במקום החוק הריבועי. G9 מפריך נאמנות ספקטרלית כללית: C1 מייצר בשלב 200 כ־14.43 פעמים את חלק הנורמה הספקטרלית הריבועית שמייצר הייחוס מעל $|k|=8$. האבלציות המתוקנות ל־gauge הן הממצא המנגנוני המעניין ביותר: החלפת הקינטיקה מתקנת כמעט לגמרי את צורת השדה, אך משאירה הטיית פאזה מוסברת של הרכיב המקומי. הערכתי היא Level 2 מבוסס, עם חומר ל־Level 3 כמחקר אבחוני ראשוני לאחר השלמת בקרה ושחזור; אין כרגע הצדקה ל־Level 4 או לטענה גורפת על עליונות C1. הכיוון המבטיח הוא זיהוי חוק תחת עירור ספקטרלי מבוקר, קיבוע gauge ובסיסים קטנים והוגנים, ולא הרחבה אוטומטית ל־C2/C3.

B. What Phase 6 establishes

מקורות התוצאות והיקף האימות

המקור העיקרי הוא המחברת Phase6_all.ipynb ב־Downloads. היא מכילה תרשימים של G1–G4, G6a, G6b, G7 ו־G9, ופלט JSON עם ערכים לכל seed ב־G1–G4. המחברת g679.ipynb מכילה אותו פלט JSON בדיוק; השוואה מלאה בין שני הפלטים החזירה שוויון. לכן אין לספור אותן כשני ניסויים בלתי תלויים. המספרים ב־JSON הזה עוגלו בארבע ספרות משמעותיות בידי קוד המחברת. ממוצעים וסטיות תקן בדוח שחושבו ממנו הם חישובים חדשים של מספרים מעוגלים, ולא גישה לדוחות Colab המלאים.

המחברת phase6_evaluation.ipynb_06 מתעדת 36 checkpoints ו־quick=False, ומשחזרת 6,102 ערכים של G5 על 18 checkpoints מול הארכיון המקורי, עם הפרש יחסי מרבי 2.62×10^{-10} . זו ראיית שחזור טובה למכשיר המדידה ולמשקולות של אותה ריצה. פלטי השלמת הזרועות והמחברות החדשות מעדכנים את הדוח מ־22 בספטמבר, שבו G1–G4, G6a, G7, G6b ו־G9 עדיין היו חסרים. יש להפריד בין מצב הריצה אז לבין התוצאות שהגיעו לאחר מכן.

ל־G5, ל־test הבסיסי ול־rollout על 100 מסלולים השתמשתי גם ב־JSON המלא בארכיון phase6-diagnosis-2026-09-22. למחברות learned_kinetic+exact_local, 11_hybrid_kinetic_ablation, gauge_identifiable_c1_12 יש תוצאות המשך חשובות שאינן ריצות אימון חדשות של C1. הן התערבויות במשקולות קפואות, עם רכיב מדויק שמגיע מהחוק הידוע. במחברת 12 מופיעים גם סעיפים להכשרת C1g, אך הפלט אומר במפורש שה־checkpoints חסרים ושהסעיפים הללו דולגו.

החישובים החדשים כאן כוללים סטטיסטיקה לפי seed, רגרסיות של עקומות G5, ספירת פרמטרים ממשיים, ניתוח היסטוריות אימון ומדידת עירור ספקטרלי בנתוני train/test המקומיים. ה־checkpoints המלאים של ריצת production אינם נמצאים בתיקיתם המקורית במחשב זה; ה־checkpoints הקצרים הוצאו מהניתוח. לכן לא בוצעה כאן הרצת inference חדשה של המודלים המאומנים. נתוני האימון המלאים כן נמצאים ב־data/nls1d-bd4e108527. ה־SHA של קובץ test המקומי שונה מזה שבארכיון Windows; ללא השוואת tensors בשני העותקים אי אפשר לקבוע זהות מלאה, גם אם הסטטיסטיקה הספקטרלית תואמת. מדידות העירור החדשות מסומנות כמדידות של העותק המקומי בעל אותו config.

שחזור הניסוי

המשוואה היא NLS פרמטרית חד־ממדית על התחום המחזורי $[0, 2\pi]$:

$$i \psi_t + \alpha \psi_{xx} + \beta |\psi|^2 \psi - V(x) \psi = 0.$$

סימני החוק ממומשים כך: הקצב הקינטי הנכון הוא $\kappa = -\alpha k^2$; הקצב המקומי הוא $v = \beta \rho - V$, כאשר $\rho = |\psi|^2$. הייחוס נוצר בפורטר split-step עם 32 תתי־צעדים לכל צעד נתונים. צעד Strang יחיד עם קצבים מדויקים הוא comparator עם ידיעת החוק, ולא מודל שלמד משוואה לא ידועה.

פרוטוקול הבסיס	פריט
N=64 על $[0, 2\pi]$, תנאי שפה מחזוריים	רשת ותחום
$\Delta t = 0.01$, 200 מעברים למסלול, $T = 2$	זמן
800 מסלולי train, 100 validation, 100 test	פיצולים
שדות מרוכבים אקראיים, מעטפת גאוסית וחיתוך חד ב־ $\text{abs}(k) \leq 8$	קלטים התחלתיים
דגימה אחידה בתחום $[1, 3]$, ללא נרמול נפרד שמוחק אמפליטודה	מסה
$\alpha \in [0.7, 1.1]$, $\beta \in [-0.4, 0.6]$	פרמטרים
משפחה אקראית חלקה, $\max \text{abs}(V) \in [0, 0.5]$, אורך קורלציה 1	פוטנציאל
חיזוי צעד אחד, relative L2 של השדה המרוכב; אין physics loss בבסיס Phase 6	loss
AdamW, lr=0.001, weight decay=0.0001, clipping=1	optimizer
patience=8, cosine schedule, עד 40 אפוקים, batch=256	batch ותקציב
0,1,2 של האימון; אותו פיצול נתונים עיקרי	seeds
מינימום validation loss; לא מינימום test ולא בחירה לפי rollout	בחירת checkpoint
160,000 זוגות זמן לאפוק, updates 625; עד updates 25,000	נפח אימון
float64/CPU מקובל ב־float32; rollout אימון ב־float64; נתונים נוצרים ב־float64	precision

ה־split מתבצע ברמת המסלול והזוגות נגזרים בתוך כל 160,000 split. זוגות זמן אינם 160,000 דוגמאות בלתי תלויות: הם 800 מסלולים עם תלות בזמן. גם 20,000 זוגות test אינם 20,000 מסלולי test. ריצות seeds שונות אינן פיצולי נתונים שונים, ולכן שונות האתחול אינה מכסה שונות של האוכלוסייה או בחירת corpus. האימונים המקוריים כוללים 18 מודלי בסיס, תשעה מודלי G6a ותשעה מודלי G7, בסך 31.36 הגיעו ל־40 אפוקים וחמישה נעצרו קודם. 29 סומנו budget-bound ו־7 converged לפי כלל תוכנה שבודק אם האפוק הנבחר מוקדם מהאחרון. הכלל אינו מבחן סטטיסטי להתכנסות; A/seed1, למשל, מסומן converged למרות אימון חלש שנעצר באפוק 13. לכל התוצאות החדשות יש תווית exploratory בהתאם לפרוטוקול, ואין להסיר אותה בדיעבד.

מהי ההטיה המבנית של C1

הצעד הוא הרכבה סימטרית $K(\Delta t/2) N(\Delta t) K(\Delta t/2)$. כל K מכפיל כל מוד Fourier בפאזה $\exp(i \Delta t \kappa)$, וכל N מכפיל כל נקודה במרחב בפאזה $\exp(i \Delta t v)$. בשני הרכיבים הקצבים ממשיים. ב־ $K0$ רשת MLP מסוג tanh מקבלת $k^2/1024$ יחד עם α, β ; אין מכפלה αk^2 מוכנסת מראש ואין מקדם αk^2 קשיח. ב־ $L0$ רשת נקודתית מקבלת ρ, V, α, β ; אין מכפלה $\beta \rho$ מוזנת מראש. לשתי הרשתות שתי שכבות חבויות ברוחב 32 ופלט סקלרי. הגודל המדויק הוא 1,217 פרמטרים בקינטיקה ועוד 1,249 ברכיב המקומי.

יש כאן `physics-informed hard architectural structure, learned generators` ו-`numerical splitting`, ולא רק תווית `physics-informed`. שימור המסה נובע ממכפילים בעלי מודולוס 1 ו-`Parseval`. ההפיכות נובעת מכך שהצעד המקומי אינו משנה ρ , ולכן הצעד האחורי קורא אותו קצב. לוקליות ותלות ב־ τ בלבד מאפשרות לכתוב `primitive` של τ לפי ρ , ולכן N הוא זרימה המילטונית מקומית; K הוא זרימה ליניארית המילטונית. הרכבתם סימפלקטית בדיסקרטיזציה. המודל גם `U(1)-equivariant`, משום שפאזה גלובלית אינה משנה את קלטי הרשתות. אלה תכונות של כל משקולות, כולל משקולות לא מאומנות, בהנחות של פוטנציאל ופרמטרים קבועים בזמן.

הוא אינו משמר בדיוק את ההמילטוניאן הפיזיקלי האמיתי. גם סימפלקטיות אינה כשלעצמה הוכחה לאנרגיה חסומה בכל מצב, לכל Δt ולכל אופק; טענות `backward-error` מחייבות תנאים על סדירות, צעד זמן והמסלול. ההערה בקוד שמנבאת `energy error bounded` היא השערת ביצועים שדורשת בדיקה, ולא מסקנה אוטומטית מהבנייה.

C1 מייצג בקלות זרימה בעלת קינטיקה אלכסונית, זוגית ב־ k , מקומית בצפיפות, ושימור מסה. הוא משתף חוק אחד בין המודים ובין נקודות המרחב. FNO חופשי יכול לייצג גם שינוי אמפליטודה, תלות בשכנים, פאזה שאינה `U(1)-equivariant`, מפות שאינן הפיכות וצימוד שאינו מתאים לפירוק הזה. C1 מתקשה בחיכוך או `gain/loss`, בקינטיקה שאינה פונקציה של k^2 , באינטראקציות מקומיות התלויות במופע השדה, וברכיבים לא־לוקליים. אלה מגבלות של `hypothesis class`, לא בהכרח תקלות אימון.

C2 מחליף את הרכיב המקומי ב־FNO על שדה הצפיפות. הוא משמר מסה והפיכות, אך תלות לא־לוקלית בצפיפות אינה מבטיחה סימפלקטיות: נדרשת אינטגרליות של שדה הקצבים, או סימטריה מתאימה של נגזרותיו. C3 קורא $\psi, \text{Im}\psi, \text{Re}\psi$ דרך FNO; המסה נשמרת, אך `U(1)` והפיכות מדויקת אובדות. שגיאת `round-trip` שלו היא מסדר $O(\Delta t^2)$ בדרך כלל. B-loop הוא FNO עם היטל מסה בכל צעד; הוא בקרה חשובה כדי לשאול מה נשאר מעבר לשימור הנורמה בלבד.

ספירת פרמטרים ויעילות

בקוד `parameter_count` סופר כל פרמטר מרוכב כאלמנט יחיד. להשוואת מספר דרגות החופש יש לספור שני סקלרים ממשיים לכל פרמטר מרוכב. C1 כולו ממשי; לכן ערבוב שתי הספירות משנה פי שניים כמעט את יחס הדחיסה.

מודל	חוב שכבות Fourier	שכבות Fourier	modes	אלמנטים לפי הקוד	סקלרים ממשיים
A	64	4	16	287,746	549,890
A-wide	64	4	32	549,890	1,074,178
B-loop	64	4	16	287,746	549,890
C1	32 ברשתות MLP	0	כל מודי הרשת בקינטיקה	2,466	2,466
C2	64 ברכיב המקומי	4	16	288,770	550,914
C3	64 ברכיב המקומי	4	16	288,834	550,978

ל־C1 יש פי 223.0 פחות פרמטרים ממשיים מ־A, ופי 435.6 פחות מ־A-wide. לפי ספירת האלמנטים של הקוד היחסים הם 116.7 ו־223.0, בהתאמה. זה מבסס קומפקטיות עם דיוק תחרותי בתנאים הנבדקים; אין עדיין עקומת Pareto שמראה ש־FNO קטן ומתאים אינו מגיע לאותו דיוק.

A-wide נוצר כדי להסיר את מגבלת `bandwidth` של A. ל־A עם `modes=16` יש משקולות Fourier רק עבור $k=0, \dots, 15$; ל־A-wide יש $k=0, \dots, 31$. ה־`Nyquist k=32` אינו פרמטר Fourier נפרד גם ב־A-wide. הבסיסים עדיין יכולים להעביר תוכן בתדרים גבוהים במסלול הנקודתי ולייצר אותו דרך אי־ליניאריות; `truncation` אינו אומר שהפלט חסר כל תוכן גבוה. A-wide אינו `baseline` מותאם פרמטרים ל־C1, וגם אינו מותאם קיבולת ל־C2.

inference cost	זמן אימון מדווח לדקה, טווח seeds	rollout 200 באחוזים	test צעד אחד באחוזים	מודל בסיס
UNKNOWN	15.25–54.01	2734.70 ± 4566.63	0.24210 ± 0.31980	A
UNKNOWN	64.19–80.23	10.96 ± 9.34	0.05357 ± 0.00321	A-wide
UNKNOWN	45.77–50.50	8.63 ± 7.26	0.05410 ± 0.00175	B-loop
UNKNOWN	6.17–7.31	5.66 ± 1.13	0.05003 ± 0.00396	C1
UNKNOWN	48.49–58.02	9.10 ± 1.01	0.06166 ± 0.00535	C2
UNKNOWN	50.72–58.18	8.31 ± 1.86	0.06242 ± 0.01019	C3

הטבלה משתמשת ב־test הבסיסי מהארכיון, ולא ב־G1 החדש. המספרים הם $\pm$ sample SD על שלושה seeds. זמני האימון הם זמני שעון היסטוריים, אינם GPU-hours מבוקרים או benchmark, וכוללים שונות בעצירה ובעומס. סכום הזמנים של כל 36 הריצות הוא כ־84.4 שעות; כ־70.6% נרשמו ל־G6a/C2. אין נתוני latency או throughput שמבססים האצת C1. inference עדיין מבצע FFTs ושתי הערכות קינטיות בכל צעד; מעט פרמטרים אינם מבטיחים אותה האצה במספר פעולות.

ביקורת הוגנות

השוואה	סיווג	מה היא מאפשרת לקבוע
A מול B-loop	FAIR לתוצאת המתכון	אותו backbone, נתונים ואימון; בודק היטל מסה כולל השפעתו על optimization
C1 מול A או A-wide	INFORMATIVE BUT CONFOUNDED	השוואת architectures בתקציב אפוקים דומה; פרמטרים, bandwidth, conditioning וקלות אימון שונים
A מול C2	INFORMATIVE BUT CONFOUNDED	כמעט אותו סדר גודל של פרמטרים; C2 מוסיף קינטיקה ופלט פאזה ותנאי סימטריה
C1 מול C2 או C3	INFORMATIVE BUT CONFOUNDED	לוקליות, גאומטריה וקיבולת משתנים יחד; אין בידוד של סימפלקטיות בלבד
single-dt מול G6a	INFORMATIVE BUT CONFOUNDED	פי שלושה זוגות ו־updates לאפוק, datasets ולוחות זמן שונים
G6b בתוך C-family	FAIR כהערכה קפואה	אותם weights נבדקים ב־ Δt אחר; אינו ניסוי עליונות מול FNO תלוי־זמן
G7 fixed מול varying α	INFORMATIVE BUT CONFOUNDED	test משותף, אך משימת אימון ופיצול corpus שונים
החלפת רכיבים ללא gauge, raw field error	NOT INTERPRETABLE לזיהוי כשל רכיב	קבוע פאזה שרירותי יכול להשתלט על המדד
החלפת רכיבים עם exact־I gauge identity check	FAIR כאבחון של weights קפואים	התערבות מוגדרת; איננה baseline של מודל שנלמד מחדש

השוואה	סיווג	מה היא מאפשרת לקבוע
G4 ברוחב 20–24 כטענה על PDE רציפה	INFORMATIVE BUT CONFOUNDED	בדיקות ההמשך מראות שגיאת רזולוציה; אין reference convergence מספק
quick מול production	NOT INTERPRETABLE	מדגמים ותקציב שונים; quick בודק plumbing בלבד

FAIR כאן אינו אומר שכל הסבר סיבתי בודד מבודד. A מול B-loop, למשל, מבודד את התוספת ההנדסית של projection, אך אותה תוספת משנה גם את ה-optimization. תנאי האימון העיקריים תואמים: loss, batch, optimizer, schedule ו-checkpoint rule. אין ראיה לכיוון hyperparameters שווה באיכותו לכל משפחה. אותה ברירת מחדל אינה מבטיחה optimization הוגן לכל hypothesis class.

G1 בקרה בתוך ההתפלגות

השערה: האם המודלים חוזים דגימה חדשה בתוך אותם תחומי α, β ותנאי קלט. השינוי הוא seed נתונים חדש 101, ולא parameter OOD. ב- $G1\ C1$ משיג $0.05152 \pm 0.00420\%$ לצעד, מול A-wide עם $0.05803 \pm 0.00388\%$ ו-B-loop עם $0.05821 \pm 0.00163\%$. הפער מול A-wide הוא -0.00651 נקודת אחוז, או 11.22% יחסית. $C1$ עדיף בצעד בכל שלושת seeds, אך ההפרש קטן ו- 95% paired t interval הוא בקירוב $[-0.01840, +0.00538]$ נקודת אחוז; עם $n=3$ אין הכרעה סטטיסטית חזקה. rollout ל-200 צעדים $C1$ מגיע ל- $5.701 \pm 1.132\%$, מול A-wide $10.902 \pm 7.004\%$ ו-B-loop $12.516 \pm 9.582\%$. סדר המודלים מתהפך בין A-wide/seed1, $C1$ /seed1 ו-B-loop/seed0 טוב מ- $C1$ /seed0. הממוצע של A הוא $5,337.6\%$ עם SD של $8,933\%$, ומונע מזנב כשל גדול; אין לתאר אותו כמודל טיפוסי בעל שגיאה ממוצעת מייצגת. הראיה חזקה לקומפקטיות ולמסה, ומרמזת על עקביות טובה באופק הנבדק; יתרון accuracy קטן הוא suggestive בלבד. הסברים חלופיים הם regularization וקצב convergence מהיר יותר של $C1$.

G2 הרחבת תחומי הפרמטרים

השערה: האם conditioning מבני משפר extrapolation ב- α, β . ההערכה מרחיבה בזמנית ל-, $\alpha \in [0.5, 1.5]$ עם seed נתונים 102. חלק מהדוגמאות עדיין בתוך תחום האימון; זה מבחן תערובת OOD/ID, ולא ממוצע טהור של דוגמאות OOD. גרף השגיאה מול α אינו מחזיק את β , מצב השדה או V קבועים. לכן הוא אינו עקומת תגובה סיבתית ל- α לבדו.

מודל	צעד אחד באחוזים	rollout 200 באחוזים	energy drift בסוף באחוזים
A	1.1162 ± 0.4570	$2.4661 \times 10^{12} \pm 2.895 \times 10^{12}$	1.3963×10^{45}
A-wide	0.64153 ± 0.17537	$1.2845 \times 10^9 \pm 2.223 \times 10^9$	1.8007×10^{34}
B-loop	0.86700 ± 0.00455	72.830 ± 9.378	31.117
C1	0.87397 ± 0.09896	66.720 ± 1.535	0.09892
C2	0.84547 ± 0.02177	70.743 ± 4.284	1.2254
C3	0.88673 ± 0.19450	71.883 ± 6.320	81.199

A-wide טוב מ- $C1$ בצעד בממוצע ב- 0.23243 נקודת אחוז: $C1$ גרוע ממנו בכ- 36.23% . מול B-loop ההבדל בצעד הוא כ- 0.8% יחסית בלבד, ללא יתרון ל- $C1$. $C1$ משתפר בכ- 8.39% בממוצע rollout מול B-loop, אך מפסיד ב- $seed0$. כלל C-family/B-loop אינם מגיעים לדיוק rollout טוב; 66.7% שגיאה אינה הצלחת extrapolation. ל- $C1$ יש drift אנרגיה קטן למרות שגיאת שדה גדולה, וזה בדיוק הניתוק בין invariant fidelity ו-trajectory fidelity.

המסה מגבילה כשל נורמה ב־C-family וב־B-loop, בעוד FNO בלתי מוגבל עלול לצאת למצב שהאימון לא כיסה. אבל ממוצע rollout ענק של A-wide אינו אומדן failure rate, ואינו אומר שכל 100 המסלולים התפוצצו. דרושים per-trajectory quantiles ושיעורי חציית סף. הראיה חזקה נגד טענת generalization של השדה, ומרמזת לטובת הגבלת כשל נורמה של architectures משמרי מסה. אי אפשר לבודד α מול β מהזרוע המקורית; מחברת gauge מוסיפה probes מופרדים, אך רק בתוך C1 ולא מול כל הבסיסים.

G3
 שינוי הפוטנציאל

השערה: האם לוקליות ותלות מפורשת ב־ V מעבירות בין משפחות פוטנציאל. α, β , bandwidth, ורשת נשארים בטווחי הבסיס; השינוי הוא cosine, Gaussian well, $V=0$, אורך קורלציה 0.3, או אמפליטודה עד 1.0. המקרים הראשונים הם שינוי משפחה או תנאי גבול של התפלגות short V ; הוא שינוי בתכולת המודים של הפוטנציאל, ולא הכנסת מודים חדשים לתנאי ההתחלה; strong מרחיב תמיכה באמפליטודת V .

פוטנציאל	C1 צעד באחוזים	A-wide צעד באחוזים	B-loop צעד באחוזים	C1 rollout באחוזים	A-wide rollout באחוזים
zero	0.05217 ± 0.00319	0.05520 ± 0.00349	0.05698 ± 0.00170	5.100 ± 0.972	6.474 ± 2.458
cosine	0.05378 ± 0.00295	0.05900 ± 0.00412	0.05926 ± 0.00155	4.753 ± 0.921	6.187 ± 2.313
well	0.04783 ± 0.00355	0.05390 ± 0.00331	0.05394 ± 0.00151	5.134 ± 1.017	9.852 ± 5.808
short	0.05154 ± 0.00298	0.22493 ± 0.10910	0.16487 ± 0.04071	5.134 ± 0.951	8.334 ± 1.313
strong	0.05209 ± 0.00309	0.06286 ± 0.00482	0.06221 ± 0.00129	5.153 ± 0.743	26.824 ± 32.940

ב־C1, short מוריד את שגיאת הצעד לעומת A-wide ב־0.17339 נקודת אחוז, 77.09% יחסית, ולעומת B-loop ב־0.11332 נקודת אחוז, 68.74%. היתרון בצעד מופיע בכל rollout. seed של C1 טוב מ־A-wide בכל seed, והפער הוא 3.2007–נקודות אחוז; paired t interval תיאורי הוא [–4.100, 2.302]. אין לתרגם את ה־interval הזה לאישור גורף אחרי עשרות comparisons; הוא משמש להמחשת גודל האפקט ושונותו.

לעומת G1, error degradation של C1 בצעד ב־short הוא בערך $1.0005 \times$, בעוד A-wide עולה $3.876 \times$ ו־B-loop $2.832 \times$. זו ההשוואה המתאימה לטענת עמידות לשינוי, מעבר לעובדה שמודל אחד קטן מלכתחילה. ב־zero/cosine/well ההבדלים בצעד קטנים יותר. ב־strong יש שיפור rollout ממוצע גדול מול A-wide, אך בעיקר עקב seed חלש של A-wide, ולכן ראה פחות נקייה מהיתרון ב־short.

ההסבר המבני הסביר הוא ש־C1 מיישם פונקציה נקודתית של V , ולכן אין צורך ללמוד מחדש routing מרחבי של הפוטנציאל. coefficient הפוטנציאל הנלמד לאחר gauge קרוב ל־1 במחברת 12. זהו mechanism candidate, לא הוכחה סיבתית: C1 ו־FNO שונים גם בגודל, ב־normalization ובתהליך האימון. C2/C3 נשארים טובים יותר מה־FNOs בצעד short אך גרועים מ־C1, כך שהמבנה של phase output מועיל כנראה, והלוקליות מוסיפה יתרון אפשרי. הסיווג הוא suggestive evidence משמעותית ל־potential generalization, עם אפקט גדול ועקבי; לא strong evidence לעליונות כללית.

G4
 הרחבת bandwidth של תנאי ההתחלה

השערה: האם הקינטיקה המשותפת של C1 מעבירה חוק למודים שאינם מעוררים באופן מהותי באימון. תנאי ההתחלה מכילים כעת $|k| \leq 12, 16, 20, 24$ במקום 8, על אותה רשת $N=64$. זו spectral support expansion פיזיקלית, ולא resolution transfer. כיוון שמסלולי האימון הלא־ליניאריים מייצרים זנבות מעל 8, נכון לומר substantially unexcited modes, ולא שמעולם לא היה שום מידע עליהם באימון.

bandwidth	C1 צעד באחוזים	A-wide צעד באחוזים	B-loop צעד באחוזים	C1 rollout באחוזים	B-loop rollout באחוזים
12	12.207 ± 0.186	15.973 ± 2.631	17.803 ± 4.077	60.360 ± 0.795	118.800 ± 15.240
16	42.950 ± 0.243	27.173 ± 3.673	34.530 ± 5.180	83.897 ± 1.261	126.533 ± 11.320
20	73.807 ± 0.212	40.857 ± 4.471	55.340 ± 3.086	95.933 ± 1.779	128.133 ± 9.352
24	92.173 ± 0.146	51.147 ± 3.465	66.307 ± 2.346	102.933 ± 0.666	128.100 ± 8.455

ב־C1 12 טוב מ־A-wide ב־3.767 נקודות אחוז, או 23.58%. ב־16 הוא גרוע ב־15.777 נקודות אחוז, או 58.06%; ב־20 וב־24 הוא גרוע בכ־80% יחסית. ההיפוך גדול משונות seeds, ומופיע בעקביות. C2 מתנהג כמעט כמו C1 בצעד בתדרים הגבוהים, למרות פי כ־223 פרמטרים ממשיים יותר; זה מתאים לכך ששניהם חולקים K0 כושל, ולא רק לכך ש־C1 המקומי קטן מדי. C3 גרוע במיוחד ב־rollout, אך עדיין מוגבל במסה. הממוצעים הענקיים של rollout של A/A-wide ב־G4 הם עדויות כשל חריפות של המתכון, לא הצדקה לקרוא ל־C1 מצליח כאשר השגיאה שלו קרובה ל־100%. C1 שומר אנרגיה יחסית טוב, אך עוקב אחרי דינמיקה בעלת דיספרסיה שגויה. מבחן הנאמנות הפיזיקלית אינו מסתיים ב־invariants.

הכשל מתחיל לפני k_wrap: בתחום האימון הסף הוא 16.9–21.2, בעוד רוויה נראית בקינטיקה כבר סביב k=10–12. לכן phase wrapping אינו ההסבר המרכזי ל־G4. גם הגדלת modes של A אינה מייצרת סופרויזן לתדרים כמעט ריקים. ב־20/24 מחברת ההמשך מצאה spatial refinement error מעל הטולרנס 0.001; יש להגביל מסקנות ל־same-grid discrete NLS. הסיווג הוא strong negative evidence להכללה ספקטרלית של המשקולות הנוכחיות, ו־informative but confounded כשמנסים להסיק דיוק של ה־PDE הרציפה.

G5a דיספרסיה ב־α קבוע

ה־probe הוא גל מישורי, $V_0=0, \alpha=0.9, \beta=0.3, A=\sqrt{2/(2\pi)}\approx 0.56419, k=0,\dots,32, \Delta t=0.01$. המסה 2 נמצאת במרכז תחום האימון. הצורה של גל מישורי היא OOD גם ב־k נמוך; ב־k גבוה מתווסף spectral support shift. עבור גל כזה v קבוע במרחב, והפאזה הכוללת נותנת $\omega=\alpha k^2-\beta A^2+V_0$. אין splitting floor מהשדות האקראיים ב־probe הזה: הצעד המדויק נכון עד עיגול מספרי.

ב־α קבוע, multiplier חושף את ω רק modulo $2\pi/\Delta t$. הסף הקינטי הוא $k_wrap\approx 18.683$, עם תיקון קטן אפשרי לפי הרכיב המקומי כשמגדירים סף לפאזה הכוללת. הפונקציה unwrap_to_reference בוחרת branch בעזרת האמת. מעל הסף העקומה unwrapped אינה שחזור עצמאי של החוק. אפילו מתחת לסף, lift המבוסס על אמת אינו מהווה כשלעצמו הוכחת התאמה אם המודל בחר branch שגוי; יש לבדוק את principal ואת index הענף.

חישובתי גרסיה חדשה של principal frequency על truth בתחום $k=0,\dots,8$. ל־C1 הקורלציה היא 0.99999980–0.99999999, slope=0.999618–1.000045 ו־intercept בין 0.00890– ל־0.00158 ביחידות frequency. relative RMSE מול האמת הוא 0.0197–0.0605%. זו התאמה כמותית טובה בתחום הנמוך, לא רק correlation גבוהה. A-wide גם טוב באותו תחום: slope=0.999997–1.001504 ו־relative RMSE=0.0741–0.1909%.

fit קינטי ישיר של C1	seed0	seed1	seed2
slope מול $-0.9k^2$, ב־ $k\leq 8$	0.999618	1.000045	0.999988
intercept לאחר $\kappa(0)$ subtraction	+0.006741	+0.002005	-0.001417
relative RMSE ב־ $k\leq 8$ באחוזים	0.07219	0.01025	0.01348

fit קינטי ישיר של C1	seed0	seed1	seed2
slope על כל k=0,...,32	0.05993	0.05953	0.06082
correlation על כל התחום	0.60845	0.60780	0.61036
relative RMSE על כל התחום באחוזים	86.70	86.76	86.56

הבדיקה הישירה היא $k(0)-k(k)$, כדי להסיר את קבוע ה־gauge. ב־ $k=8$ הקצב כמעט נכון: 57.55– עד 57.60– מול 57.6–. ב־ $k=16$ הוא 78.78– עד 79.98– מול 230.4–, וב־ $k=32$ הוא נשאר באותו plateau מול 921.6–. שגיאת הקצה היא 65.29%–65.81% ב־ 16 ו־91.32%–91.45% ב־ 32 . אם מחשבים במקום זאת רגרסיה על העקומה שהורמה בעזרת האמת, מתקבל $slope \approx 0.998-0.999$ גם על כל התחום, אך עם $relative RMSE \approx 33.3\%$ ו־ $intercept \approx -20$. זו דוגמה ממשית לאופן שבו slope יפה ובחירת branch יכולים להסתיר כשל.

K0 עם tanh ומשקולות סופיות הוא חסום. במשקולות האלה $|w_{out}|_1 \approx 102-107$, $|k(x)-k(y)| \leq 2$, פחות מהפרש הקצב הנדרש ב־ $k=16$. זו מגבלה של המשקולות הנוכחיות; רשת אחרת מאותה משפחה יכולה להגדיל את החסם ולקרב היטב טווח סופי רחב יותר. אבל שום רשת tanh כזאת עם משקולות סופיות אינה מייצגת חוק ריבועי לא־חסום כאשר $k \rightarrow \infty$. K1 מוסיף מכפלה כקלט אך אינו מסיר את חסימות הפלט; K2 מכניס את החוק הריבועי מראש ולכן הוא ablation עם prior מפורש. הסיווג: strong evidence להתאמה בתחום המודים המאוכלס, strong negative evidence לחוק מועבר בתדרים גבוהים.

G5b
 נגזרת פאזה לפי α

כאן משתנה רק α על הגריד 0.7, 0.75, ..., 1.1; $V=0$, $\beta=0.3$, אמפליטודה ומוד קבועים. היעד הוא d $\arg(m)/d\alpha = -k^2\Delta t$. קוראים increments באמצעות $\arg(m_{j+1} \text{ conj}(m_j))$; עם $\Delta\alpha=0.05$ וב־ $k=32$ מתקבל $\Delta\alpha$ $k^2\Delta t=0.512<\pi$, ולכן המדידה אינה נפגעת מ־wrapping של ה־increments. זו מדידת slope בתוך תחום הפרמטרים, לא extrapolation ל־ $\alpha=0$.

מודל	שגיאת נגזרת מקסימלית ב־ k=8 באחוזים	ב־ $k=16$	ב־ $k=32$
A	7.34 ± 6.94	96.82 ± 1.12	99.11 ± 0.44
A-wide	3.60 ± 0.60	95.15 ± 1.19	99.22 ± 0.39
C1	4.85 ± 2.75	97.17 ± 0.23	99.29 ± 0.06
C1 multi-dt	1.38 ± 0.058	97.89 ± 0.32	99.47 ± 0.081

המדד הוא מקסימום שגיאה על שמונת מרווחי α בכל seed, ואז $\mu \pm SD$ על seeds. הוא אינו RMSE, ואינו mean slope error. התאמת ω יפה בנקודת $\alpha=0.9$ ב־ $k=8$ אינה מבטיחה נגזרת נכונה בכל טווח α ; זו הסיבה שאין סתירה בין G5a המדויק יחסית לבין שגיאה של כמה אחוזים ב־G5b. גם כאן כל המודלים נכשלים ב־ $k=16$, לפני סף wrapping של מרבית התחום. multi-dt משפר את slope המקומי ב־ $k=8$ אך לא מזהה את התלות הגבוהה ב־ α .

הקוד כולל גם alpha continuation שמתחיל ב־ $\alpha=0$. זו extrapolation בפרמטר ודרישת anchor נוספת. אין להשתמש בה כדי להסיק שמידע הנגזרת בתוך $[0.7, 1.1]$ זוהה או לא זוהה. קורלציות של phase drift במחברת 12 הן של מדד אחר, ולא תוצאת G5b. הסיווג: strong negative evidence שהמשקולות למדו $k^2\alpha$ מועבר על פני כל המודים; suggestive improvement של מתכון multi-dt בתוך התמיכה הנמוכה.

G6a
 אימון על שלושה צעדי זמן

המודלים C1,C2,C3 אומנו על $\Delta t \in \{0.005, 0.01, 0.02\}$. אלו צעדי זמן שנראו באימון, ולכן בדיקתם אינה time-step extrapolation. המודל חייב לייצג generator שימושי מעבר לתמונה אחת של flow map, אך שלושה צעדי הזמן כאן קומנסורביליים: 0.005 הוא יחידת הזמן הבסיסית. אם ידועה רק פאזה על גריד זמנים כזה, עדיין קיימות משפחות קצבים הנבדלות ב־multi-dt. $2\pi/0.005$ כזה אינו הוכחה לזיהוי generator יחיד ללא הנחות נוספות.

Δt	C1 צעד באחוזים, mean [min,max]	C2	C3
0.005	0.02101 [0.01986,0.02219]	0.01862 [0.01746,0.01999]	0.03493 [0.01708,0.05329]
0.01	0.04140 [0.03908,0.04377]	0.03629 [0.03392,0.03906]	0.06895 [0.03257,0.10610]
0.02	0.07962 [0.07492,0.08435]	0.06706 [0.06210,0.07279]	0.13390 [0.05940,0.20890]

המקור השמור מספק כאן mean/min/max, לא את שלושת הערכים; אין די מידע ל־SD מדויק. error bars במחברת הם טווח seeds, לא confidence intervals. ב־test הבסיסי ב־C1 multi-dt, $\Delta t=0.01$, משפר rollout מ־5.660% ל־3.443%, 39.2% יחסית, ו־C2 מ־9.104% ל־3.260%, 64.2% C2 multi-dt טוב מ־C1 במוצע השדה רק בכ־5.3%, והסדר אינו קבוע בכל seed. מדדים לאחר יישור פאזה וצפיפות בארכיון מעדיפים את C1; אלה secondary outcomes ולא תחליף בדיעבד למדד הראשי.

כל אפוק multi-dt מכיל 480,000 זוגות ו־1,875 updates, פי שלושה מהבסיס. בנוסף 200 צעדים הם T=1,2,4 בהתאמה, כך שספקטרום ה־rollout בין Δt שונים אינו נמדד באותו זמן פיזיקלי. בדיקות ההמשך ב־hybrid כן מחזיקות T קבוע, אבל ללא baseline FNO תואם. האפקט המבוסס הוא שהמתכון המורחב משפר low-band prediction של C1/C2; אין בידוד של השפעת multi-dt מעוד optimization ונתונים. הסיווג: suggestive evidence למתכון אימון משופר, inconclusive לזיהוי סיבתי של תועלת של multi-dt, ו־negative evidence לתיקון הכשל הקינטי הגבוה.

G6b
 העברה בצעד זמן ללא אימון

המשקולות של הבסיס ב־ $\Delta t=0.01$ נבדקות ב־0.005,0.01,0.02 על גלים מישוריים. עבור C1/C2, density של גל מישורי אינו משתנה בצעד K, ולכן נבדקת בעיקר אותה פונקציית קצב כפול Δt חדש. הגרפים מראים התאמה טובה ב־ $k \leq 8$ ועלייה חדה בשגיאת frequency באזור $k \approx 10$. הסף המסומן עובר מ־26.42 ל־18.68 ול־13.21 כאשר מגדילים Δt ; הכשל מתחיל לפני הסף בכל שלושת המקרים.

אין בסיכום המספרי של Phase6_all את מערכי G6b המלאים. לכן לא הומרו פיקסלים של התרשים למספרים מדויקים או ל־SD. המשמעות הנתמכת היא שהקצב הנמוך נגיש להעברה, בעוד אותו plateau קינטי נשאר. ירידות מחודדות בשארית בתדרים גבוהים הן תוצאה אפשרית של בחירת branch בעזרת הייחוס, ואינן recovery של החוק. גם |mean residual| על seeds יכול להסתיר ביטול סימנים; צריך לדווח mean absolute residual ו־quantiles.

A, A-wide ו־B-loop רשומים unsupported משום שהארכיטקטורה הנוכחית אינה משתמשת ב־ Δt . זו מגבלה של baseline זה, לא משפט אי־יכולת על FNO: baseline שמקבל Δt כערוך או שמנבא generator יכול להיבנות. לא נמדדה כאן עליונות של C1 מול FNO תלוי־זמן. הסיווג: weak/suggestive evidence ל־low-band inconclusive, negative evidence ל־dt transfer, לתדרים גבוהים, inconclusive ליתרון מול baseline מתאים.

G7
 קיבוע α בזמן האימון

ההשערה היא ששונות ב־ α מספקת מידע על התלות הקינטית ומפחיתה ambiguity. קבוצת fixed אומנה ב־ $\alpha=0.9$, עם β ושאר הנתונים בטווחי הבסיס, ונבדקת מול varying על אותו test של α קבוע. המשימה של fixed קלה יותר ופיצול האימון שלה שונה. high/low band ratio נועד לנרמל הבדלי קושי, אך אינו מנטרל אותם באופן מלא: שיפור low-band בלבד יכול להגדיל ratio גם בלי הידרדרות בתדרים הגבוהים.

fixed high-band error	varying high-band error	fixed ratio, mean [min,max]	varying ratio, mean [min,max]	מודל
7.783	87.37	274.0 [229.0,319.2]	159.0 [92.94,224.1]	A
65.36	72.39	2746 [1659,3586]	3650 [3211,3910]	C1
81.10	47.15	606.1 [410.9,867.5]	859.0 [801.4,968.7]	C2

שגיאות band בטבלה הן relative L2 ביחידות יחס, לא אחוזים; למשל 72.39 הוא 7,239%. הן גבוהות במיוחד משום שהיחס כמעט ריק מעל $k=18.683$. ל־varying C1 אין שיפור ב־ratio; fixed נמוך בכ־24.8% במוצע והטווחים חופפים. ב־A יחס varying נמוך יותר, אף שהשגיאה הגבוהה המוחלטת שלו גרועה בהרבה: low-band error שלו הוא 0.9152 לעומת 0.02843 ב־fixed. זו דוגמה ברורה לכך ש־ratio טוב לכאורה אינו מספיק. ב־varying high-band C2 טוב יותר, אך גם low-band משתנה.

mean(high/low) אינו בהכרח mean(high)/mean(low); אי אפשר לשחזר את ה־ratio מהערכים הממוצעים בטבלה. G7 אינו מחזיק מודים גבוהים מאוכלסים ואינו מודד ישירות $dk/d\alpha$. לכן הוא אינו מכריע את תיאוריית הזיהוי ב־ α , והכיוון ב־C1 אינו תומך בנרטיב המקורי. הסיווג: inconclusive, עם negative evidence נגד הטענה הספציפית שה־varying recipe הקיים שיפר את המדד של C1.

G9 cascade לא־ליניארי

הניסוי מתחיל בשמונה שדות אקראיים מאותו $\alpha=0.9$, $\beta=0.3$, $V=0$, $\text{probe seed}=0$, $\text{bandwidth}=8$; מודלים מכל שלושת training seeds נבדקים על אותם שמונה תנאי התחלה. נשמר ספקטרום כל 25 צעדים עד 200, $T=2$. המדד הוא fraction של $|\eta|^2$ מעל $|k|=8$, כלומר spectral norm power. זה אינו ההמילטוניאן NLS ואינו לבדו כמות הזרימה בין מודים. המטרה היא התאמה לייחוס, לא fraction נמוך ככל האפשר.

הבדל מוחלט מהייחוס	יחס לייחוס	fraction בסוף	מודל
0	1.000	1.131×10^{-5}	reference
$+2.212 \times 10^{-5}$	2.956	3.343×10^{-5}	A
-2.802×10^{-6}	0.7523	8.508×10^{-6}	A-wide
$+2.750 \times 10^{-6}$	1.243	1.406×10^{-5}	B-loop
$+1.519 \times 10^{-4}$	14.430	1.632×10^{-4}	C1
$+1.245 \times 10^{-4}$	12.007	1.358×10^{-4}	C2
$+2.864 \times 10^{-5}$	3.532	3.995×10^{-5}	C3

C1/C2 הם הגרועים בין המודלים ב־tail fraction בניסוי הזה. הספקטרום מתחיל נכון, ואז הזנב שלהם גדל מעל הייחוס. זה מתיישב עם קינטיקה שגויה, הפוגעת ביחסי הפאזה ובביטול התנודות שמווסתים mode coupling, אך המנגנון המדויק דורש התערבות ולא נובע מספירת הפרמטרים. B-loop ו־A-wide קרובים בהרבה למדד הזה. A יכול להיות קרוב יותר ב־cascade ועדיין לא יציב על test אחר; זו אינה סתירה.

ה־fraction קטן במונחים מוחלטים: אפילו C1 הוא 0.01632% מהמסה הספקטרלית. לכן $14.43 \times$ אינו אומר פי 14 שגיאת שדה כוללת. הוא כן כשל במדד שהניסוי תוכנן לבחון. אין בפלט המסכם SD או per-seed cascade arrays, ואין replication על יותר משמונה ICs בזרוע המקורית. הסיווג: negative evidence משמעותית לנאמנות cascade של C1, עם גבול scope ברור.

האבלציות המשלימות וה־gauge

קיימת חירות $v \rightarrow v+c(\alpha,\beta)$, $k \rightarrow k-c(\alpha,\beta)$. היא משאירה את הצעד המלא זהה, משום שהפאזות הגלובליות מתקזזות. c יכול להיות פונקציה של הפרמטרים בכל מערכת אוטונומית; הוא אינו חייב להיות קבוע אחד לכל

corpus. לפיכך אי אפשר לשפוט א או v מוחלטים, או להחליף רק אחד מהם, בלי לבחור נציג gauge. הבחירה במחברת 12 היא $c=\alpha\theta(0;\alpha,\beta)$, כך ש- $\kappa(0)=0$ ו- $\kappa=v+\alpha\theta(0)$.

מחברת learned_kinetic+exact_local מראה של- $C1$ יש tail fraction של $17.29\times,12.10\times,13.89\times$ מהיחס לפי seed. עם learned kinetic + exact local מתקבל $0.86\times,0.78\times,0.81\times$; עם learned kinetic + exact local שניהם exact נותנים $1.007\times$. לערך. metric הספקטרום אינו רגיש לפאזה גלובלית, ולכן לאבלציה הזאת יש ערך גם לפני gauge. היא ממקמת את כשל ה-cascade בעיקר בצד הקינטי של weights אלה, אך אינה מוכיחה שהרכיב המקומי מדויק כ-law.

מחברת 11 מרחיבה ל-36 cases, חמישה probe seeds ו-16 ICs לכל probe, עם שלושה training seeds ו-2,000 rollouts עד צעדים. בפלט שלה ההיבריד הלא-מתוקן גרוע ב-raw field error פי כ-24.6 מ- $C1$ ב- $G1$. זה לא אומר שהחלפת קינטיקה נכונה מזיקה מהותית: ה-aligned error שלו נמוך בהרבה. מחברת 12 משחזרת את ההבחנה ומוסיפה gauge לכל החלפה. כאשר שתי המחציות נלמדות, transformation ל-gauge הנבחר משמר את הפלט המלא עד identity tolerance של 10^{-12} בקוד הבדיקה.

אותו hybrid aligned	C1 aligned error	local מתוקן exact kinetic gauge	C1 raw error	G4 bandwidth 12, probe1000
0.004214	0.6911	0.06147	0.6993	seed0
0.004278	0.6612	0.05089	0.6694	seed1
0.003980	0.6640	0.04859	0.6759	seed2

אלה יחסי $L2$, לא אחוזים. אותה התערבות מתקנת שגיאת שדה גדולה בלי optimizer או שינוי ברכיב המקומי. בטבלה המצטברת של מחברת 12, על $16\times5\times3$, היחס הגאומטרי של hybrid/ $C1$ ב- $G4-12$ הוא 0.0446 ל-raw error, עם interval תיאורי $[0.0331,0.0612]$, ו-0.00429 ל-aligned error, עם $[0.00333,0.00552]$. כלומר שיפור בערך $22.4\times$ במדד הראשי ו- $233\times$ במדד המיושר. learned kinetic + exact local אחרי gauge נשאר קרוב ל- $C1$ בשגיאה המיושרת, $ratio\approx1.00$. ב- $bandwidth16$ מתקבל $ratio=0.0344$ ל-raw aligned $ratio=0.00423$. ב-24 הכיוון נשמר, אך שם הבדיקה המרחבית של הייחוס נכשלת ואין להרחיב את הטענה לרצף.

ב- $hybrid$, $G1$ מתוקן gauge שונה הרבה פחות בצורה אך לא בהכרח בפאזה: לדוגמה, $seed0$ raw=0.06132, aligned=0.004225, מול aligned=0.05237, $C1$ raw=0.06307, שני מדדים עונים על שתי שאלות שונות. בדיקה בפאזה מיושרת היא secondary diagnostic; היא אינה הצדקה להכריז שהמודל הראשי פתר את משימת חיזוי ψ .

מחברת 12 חוזה את drift הפאזה הגלובלית באמצעות סכום Δt של השגיאה המקומית $\delta q=v-(\beta p-V)$, משוקללת ב- q . ההתאמה הנמדדת מגיעה ל- $slope\approx1.000-1.001$ ו- $relative\ residual\approx0.002-0.003$, עבור צפיפיות hybrid וגם reference. זה חזק יותר מדיווח $correlation\approx1$ בלבד. עם זאת regression slope כאן נכפה דרך הראשית; intercept לא הותאם ולא מופיע בפלט. לא זמינים כאן המספרים המלאים של endpoint correlation או CI. זו בדיקת מנגנון within the tested trajectories, לא הוכחת חוק מקומי בכל ההתפלגות.

gauge לאחר local law	seed0	seed1	seed2	אמת
coefficient של βp	0.9540	0.9384	0.9561	1
coefficient של v	-0.9827	-0.9853	-0.9828	-1
intercept	-0.0149	-0.0065	-0.0067	0
coefficient של α -mean α	-0.3295	-0.2717	-0.2147	0
relative RMSE מול החוק	0.1859	0.1574	0.1419	0

ה־fit נעשה על 256 שדות probe ב־G1, כל נקודות הרשת ומשקולות ρ . אלפי grid points אינם אלפי systems עצמאיות. coefficients טובים של ρ ו־V עדיין משאירים 14.19%–18.59% weighted relative RMSE מול החוק המקומי, וחלק ממנו אינו מוסבר ב־fit ליניארי. ב־fit, $\alpha=0.9, V=0$, נפרד של δq מול ρ נותן slope/β בין 0.166– ל־0.095 לפי seed β . זו הטיית אי־ליניאריות שיטתית בתחום הזה, ולא רק offset. אין להסיק התאמה מדויקת מ־ $\text{coefficient}\approx 0.95$ בלבד, וגם אין לקרוא ל־fit הזה law identification גלובלי.

מדוע subtraction $\kappa(0)$ משנה גם coefficients שאינם $\kappa(0; \alpha, \beta)$ intercept? תלוי בפרמטרים, ויש correlations בין פרמטרים, densities ומשקולות ה־fit. לכן ה־regression אינו פירוק פיזיקלי מזוהה, ו־gauge משנה את נציג הפונקציה שאותו מקרבים. זה אינו שינוי במשקולות או במשפחת המפות הכוללות.

ה־bootstrap intervals במחברות הם תיאוריים, אינם מתוקנים לריבוי tests, ויש רק שלושה seeds של weights. חמישה batches מספקים 80 ICs עצמאיים יותר על ציר הקלט, ולא 15 אימונים עצמאיים. עקומות הזמן נמדדות שוב ושוב על אותם מסלולים. הראיה המנגנונית חזקה עבור המשקולות הקפואות האלה; היכולת של מודל C1g מאומן להימנע מן הפיצוי נשארת NOT TESTED.

optimization מול representation

C1 בסיסי הגיע ל־40 אפוקים בכל seed; train loss הוא בערך 0.0004562, 0.0004855, 0.0005161, וה־validation הנבחר 0.0004865, 0.0005196, 0.0005552. הפערים קטנים וה־validation משתפר רק 0.69–1.05% בחמשת המעברים האחרונים. זו אינה תמונת overfitting חריפה. ב־A seeds 0/2 עדיין נרשמת ירידה של 17.77%–22.53% ב־validation בתקופה המקבילה, וב־A-wide כ־21%–24%. ב־A/seed1 loss האימון גבוה וה־early stopping בחר אפוק 4 מתוך 13; זה failure of recipe או optimization, לא מדד נקי של הקיבולת המיטבית של FNO.

cosine מוריד lr כמעט לאפס, ולכן plateau אינו מוכיח מינימום טוב. train loss נמדד לאורך האפוק כשהמשקולות משתנות, בעוד validation נמדד בסופו; אין לפרש יחס train/val כתוחלת generalization gap מדויקת. nevertheless אין בנתונים האלה מקרה נקי שבו C1 מאומן פחות טוב אבל מכליל טוב יותר רק עקב regularization. הבעיה של spectral law נפרדת: נמוך loss אינו מעניש מספיק תדרים כמעט לא מאוכלסים.

המדידה החדשה על 800 מסלולי האימון המקומיים וכל 201 frames מצאה fraction ממוצע של 1.104×10^{-5} מעל 8, 2.473×10^{-8} מעל 15 ו־ 3.226×10^{-9} מעל 18. המקסימום מעל 15 הוא 4.591×10^{-6} . בתנאי ההתחלה fractions מעל cutoff הם ברמת roundoff. כלומר יש זנב לא־ליניארי, אך loss הכולל נותן לו משקל זעיר. ספירת עוד epochs אינה יוצרת persistent excitation; שילוב משתני α אינו פותר מחסור בסיגנל של המוד שאמור לשאת את התלות ב־ α .

פיזיקה וסטטיסטיקה של rollout

המודלים משמרי המסה שומרים אותה ב־float64 עד עיגול: ב־test הבסיסי C1 drift בסוף $\approx 4.83 \times 10^{-14}$, B-loop $\approx 1.77 \times 10^{-15}$. C1 drift האנרגיה הפיזיקלית הממוצע הוא 0.06323%, לעומת A-wide 3.4210%, B-loop 0.06771%, C2 44.2365%, ו־C3 0.27702%. קרוב ל־C1 באנרגיה ללא הבטחת סימפלקטיות, ולכן אין attribution סיבתי לסימפלקטיות לבדה.

ב־test הבסיסי A/seed2 הוא דוגמה לסכנת mean: חציון rollout כ־3.61%, שבעה מתוך 100 מסלולים מעל 100% שגיאה, והממוצע נשלט במסלול עצום. ב־A/seed1 77% מתוך 100 עוברים 100%. ל־B-loop המספרים הם 0,1,4 לפי seed; ל־A-wide 3,0,2; ל־C1 0,0,0. אלה failure rates עבור סף מפורש באופק 200 של ה־DOO test המקורי, לא של G2/G4, ולא אומדן אוכלוסייה מבוסס על 300 ICs שונים: אותם 100 קלטים חוזרים על פני שלושה אימונים.

שימור מסה מבטיח חסם שימושי אך חלש: אם גם target וגם prediction בעלי אותה נורמה, relative L2 ביניהם ≥ 2 , כלומר עד 200% גם כשהפאזה/הצורה שגויות לחלוטין. לכן היעדר norm blow-up או NaN של C1/B-loop אינו הוכחה לנכונות dynamics. אין נתוני Lyapunov, error growth law, mode coupling מדויק או aliasing audit מלא שמבססים יציבות לכל זמן. ה־G8 extension במחברת 11 בוצע עד 2,000 צעדים, אך הפלט הנגיש אינו כולל טבלת metrics מלאה; אין כאן השוואת long-time accuracy הוגנת מול FNO לכל המדדים.

תוצאות Phase 7 כתוספת ולא כחלק מ־Phase 6

metrics (1).json, Phase 7 הוא עם $\lambda=100$ horizon ושני λ sweeps של A ו־C1. אין לערבב אותו עם G7. הוא מספק בדיקה נוספת נגד נרטיב עליונות המבנה: $\lambda=0.01$, $A+PDE$ משיג $\text{mean rollout100}=2.511\%$, לעומת C1 הבסיסי 2.914% . $C1+PDE$ ב־ $\lambda=0.01$ נשאר 2.914% , כמעט בלי שינוי. ב־ $\lambda=1/10$ הביצועים של שתי המשפחות נפגעים; ב־ $\lambda=10$ drift אנרגיה ממוצע ענק. C1 שומר מסה ואנרגיה יחסית טוב גם כשה־trajectory error גדל.

הפרוטוקול המדווח של λ positive תואם 40 אפוקים ו־batch256, אך $\lambda=0$ משתמש במשקולות היסטוריות בעוד $\lambda>0$ אומנו במסלול workflow חדש. horizon100 ו־evaluation subset אינם horizon200 על כל G1–G4. מדווח גם confound של residual מסוג Crank–Nicolson מול split-step. לכן זו תוספת suggestive לכך שה־baseline ניתן לשיפור, לא תיקון מלא של fairness ב־Phase 6. היא מחזקת את הדרישה להשתמש ב־baseline מאומן כראוי לפני טענת paper.

C. What Phase 6 does NOT establish

אין ראיה לכך ש־C1 לומד dispersion law מחוץ לתמיכה הספקטרלית שעוררה את האימון; G4/G5 מספקים ראיה נגד הטענה במשקולות הנוכחיות. התאמה של κ בתחום נמוך ו־good test error אינן identifiability של generator על פני כל κ . גם תנאי $\kappa(0)=0$ אינו פותר ambiguity של פאזה דגומה, התאמה בין kinetic/local. שאינה קבוע בלבד, או תיקון splitting תלוי־ Δt .

אין הוכחה ל־parameter efficiency על Pareto frontier. קיימים שני גדלים של FNO, אך A-wide משנה bandwidth וקיבולת יחד, ושניהם גדולים בהרבה מ־C1. אין FNO בגודל 2,500~ פרמטרים ממשיים, capacity sweep קטן או compute-matched baseline. אין די מידע לטעון ל־inference speedup או פחות FLOPs באותה accuracy.

אין כאן sample efficiency: אף שהנפח הכולל קטן יחסית למדדי ML אחרים, אין ב־Phase 6 עקומה של מספר מסלולים מול error, עם אימון מחדש מ־scratch. חמישה probe seeds, או tensor גדול של זוגות זמן, אינם ניסוי על כמות נתוני האימון.

אין תוצאות production נגישות שמבססות resolution transfer של C1 מול FNO ב־ $N=128$. בדיקות $2N$ במחברות hybrid הן בדיקות הייחוס, לא העברת המודל. ריסמפלינג של אותו bandwidth היה בודק resolution transfer; הכנסת k חדשים הייתה spectral extrapolation. אף אחד מהם אינו נובע מכך ש־C1 מבצע FFT.

אין הוכחה ש־C1 משמר את ההמילטוניאן הפיזיקלי בדיוק או משחזר cascade נכון. invariants טובים יכולים לחיות לצד trajectory error של כ־100% ו־tail power שגוי פי 14. אין energy-drift theorem אמפירי לכל זמן, ואין separation של symplecticity מ־parameter sharing ו־locality, capacity.

אין זיהוי סיבתי של יתרון multi-dt, ואין baseline התלוי ב־ Δt ב־G7. G6 אינו מראה בבירור ששונות α עזרה ל־G2. C1 אינו מפריד α, β ואינו נותן ממוצע על OOD-only points; טענה ל־parameter extrapolation מוצלח אינה מוצדקת.

אין תוצאות מאומנות של C1g או C1g+PDE במחברת 12. הכותרת של המחברת והקוד שלה אינם תוצאה. בדיקות שנדפסו PASS מול tolerances רחבים משחזרות observations קודמים; הן אינן בדיקה prospectively registered של hypothesis חדשה.

אין הערכת novelty מלאה מול ספרות neural operators גאומטריים, ואין תוצאות misspecification מבוקרות של הריצה המלאה שמבססות את Story F במובן של שינוי המשוואה. המבנה הקשיח יוצר מגבלות צפויות, אך prediction theoretical boundary אינו experiment שבוצע.

לכל הטענות החזקות האלה: **The current evidence is insufficient to establish this claim**. יש גם מגבלת provenance: דוחות Colab של G1–G9 ו־hybrid אינם כולם נמצאים כאן כ־raw JSON; חלק מן האנליזה נשען על outputs מוטמעים, rounding ותרשימים. הסטטיסטיקה העצמאית כאן לא מחליפה החזרת manifests, arrays ו־checkpoints מלאים למערכת שחזור אחת.

D. C1 vs FNO

Property	C1	FNO/A	Evidence
In-distribution accuracy	צעד ~0.050–0.052%; תחרותי	A-wide ~0.054–0.058%; A seed רגיש ל־seed	G1 ו־IID test seeds 3 יתרון קטן אינו מוכרע עם
Parameter efficiency	2,466 ממשיים; קומפקטיות הוכחה	A 549,890; A-wide 1,074,178	Pareto efficiency UNKNOWN; אין קטן מותאם
Parameter OOD	G2 rollout 66.72%; יציב בנורמה אך לא מדויק	A-wide צעד טוב יותר, rollout עם failures ענקיים; B-loop 72.83%	אין successful extrapolation כללי
Spectral OOD	כשל חד, step 42.95% ב־band16	A-wide 27.17% ב־band16, גם הוא נכשל	G4; כשל C1 קודם ל־wrapping
Dispersion fidelity	מצוין ב־k≤8; plateau k≥10–12	low band; G5b high-k טוב כושל גם עם wide	G5 ו־direct k fits
Resolution transfer	UNKNOWN / NOT TESTED בתוצאות production הנגישות	UNKNOWN / NOT TESTED באותו scope	2N reference check אין model transfer
Sample efficiency	UNKNOWN / NOT TESTED ב־Phase 6	UNKNOWN / NOT TESTED	אין training-data sweep
Long-rollout stability	מסה מוגבלת; fewer failures עד 200; accuracy תלוי shift	A רגיש לזנב; B-loop mass- bounded; baseline לשיפור	IID tails, G1–G4; 2000-step superiority UNKNOWN
Physical invariants	C1 מסה קשיחה; reversible/symplectic; H_true אינו קשיח	A ללא ערבות; B-loop מסה קשיחה	float64; ומדידות cascade של C1 גרוע

E. Most interesting finding

הממצא היחיד המעניין ביותר הוא הניתוק בין חיזוי הצעד/שימור גאומטרי לבין זיהוי הרכיבים, והיכולת להסביר אותו באמצעות התערבות קינטית ו־**gauge**. בשלושה seeds של C1, על G4-bandwidth12 עם probe1000, שגיאת שדה מיושרת של 66.1%–69.1% יורדת ל־0.398%–0.428% כאשר מחליפים את הקינטיקה בקינטיקה המדויקת ומשאירים את הרכיב המקומי קפוא. ב־80 ICs וחמישה probe batches, הטבלה המצטברת נותנת raw ratio=0.0446 ו־aligned ratio=0.00429. במקביל הפאזה הגלובלית שנותרה מוסברת על ידי הטיית הקצב המקומי עם slope≈1 ו־residual≈0.2–0.3%. זהו ממצא אבחוני על המקום שבו הסתתרה השגיאה, ולא ניצחון .leaderboard

ההתנגדות החזקה ביותר של reviewer היא שה־intervention מוסר למודל את החוק הקינטי האמיתי; C1 עצמו לא למד אותו, ולכן improvement גדול יכול להיות תיקון oracle צפוי של MLP רווי שמאומן על bandwidth צר. יתרה מזאת aligned error הוא מדד משני, וה־gauge הוגדר לאחר צפייה בכשל. כדי להפוך זאת לתרומה צריך להראות מתי, באיזה excitation ובאיזה budget, החוק המזוהה משתפר באמת מול baseline מתאים, ולא רק שהכנסת החוק המדויק מתקנת dynamics.

אם נדרש לבחור ממצא חיובי יחיד מול baseline: ב־C1, G3-short משמר one-step error≈0.05154%, בעוד A-wide עולה ל־0.22493% ו־B-loop ל־0.16487%, למרות כ־436/223 פעמים פחות פרמטרים ממשיים. זהו candidate ל־locality-induced potential generalization, עם צורך בבקרה על גודל, compute ו־normalization.

F. Biggest weakness / confound

החולשה המרכזית היא שעיקר האימון אינו מעורר את המודים שעליהם אמורה להישען טענת spectral law learning, ובמקביל ה־baseline אינו מותאם גודל או convergence. variation ב־ α יכול לספק מידע על slope רק במקום שבו multiplier של המוד משפיע באופן מדיד על loss. הוא אינו יוצר אותו מידע בתדרים בעלי $\text{fraction} \approx 10^{-8}$. לכן חשוב יותר לשנות experimental design מאשר רק להוסיף epochs.

ה־confound הגדול ביותר לטענה חיובית הוא optimization של A. seed חלש ועקומות שעדיין יורדות מגדילים מאוד את הפער הממוצע ב־rollout. B-loop, A-wide ו־A+PDE הם ביקורות חזקות יותר מ־A לבדו, והם משנים את הסיפור: שימור מסה אינו ייחודי ל־C1, ו־PDE penalty קטן כבר משפר A באופן 100 לרמה דומה או טובה. בלי baseline recovery, claim על generalization intrinsic אינו defensible.

יש גם confounds חשובים במדדים: raw swaps לפני gauge, bands כמעט ריקים, |seed-mean residual| במקום mean|residual|, horizons שונים ב־G6a והיעדר reference spatial convergence ב־high bandwidth. על כל אחד מהם אפשר להתגבר; אף אחד מהם אינו סיבה למחוק את התוצאות השליליות או להחליף מדד ראשי בדיעבד.

G. Paper-worthy claim, if any

Conservative claim

ב־NLS חד־ממדי בדיסקרטיזציה ובתקציב האימון האלה, learned pointwise phase splitting surrogate בן 2,466 פרמטרים ממשיים עם דיוק תחרותי בתחום המאוכלס, שימור מסה קשיח ועמידות נצפית לשינוי הפוטנציאל. אותו מודל נכשל ב־spectral law transfer למרות invariant behavior טוב. frozen component interventions מבחינות בין כשל קינטי בתדרים חדשים לבין הטיית פאזה מקומית, ומראות שחיוזי trajectories אינו מספיק לזיהוי הרכיבים.

Stronger claim

אחרי בקרה על excitation, מספר פרמטרים, updates ובחירת checkpoint, אפשר אולי לטעון שלוקליות ו־parameter sharing משפרים למידת generator ושליטה ב־rollout מחוץ להתפלגות, בתנאי שה־corpus מזהה את החוק. לחלופין ייתכן שהתרומה תהיה negative result: geometric structure מגביל norm failures אך אינו מקנה identifiability של kinetics בלי gauge ו־persistent excitation. שתי האפשרויות ראויות למחקר; הניסוי הבא צריך לאפשר לשתייהן להתגלות.

Claim we should NOT make

אין לטעון ש־C1 לומד את חוק Schrödinger ומכליל אותו לתדרים שלא ראה, שמבנה סימפלקטי מבטיח dynamics נכון לטווח ארוך, שהוא יעיל יותר מכל FNO או שהוא משיג sample efficiency/zero-shot super-resolution. אין לטעון ש־multi-dt פתר phase ambiguity, שהחלפת kinetic precise מוכיחה law recovery, או שאנרגיה נמוכה מוכיחה cascade נכון.

רמת התרומה והחידוש

Level 2 כעת. יש שאלת MSc טובה, מדידות חוזרות, מנגנון שניתן לבדיקה ושלילה ברורה של נרטיב פשטני. **Level 3** אפשרי למחקר אבחוני ראשוני אם raw artifacts יוחזרו, העיקר ישוחרר בכמה seeds ופיצולי נתונים נוספים, והבקורות המכריעות יבוצעו. **Level 4** אינו מבוסס כעת: חסרים isolation סיבתי, baselines קטנים וראיית novelty של הטענה הספציפית. אין הצדקה לסווג הכול כ־Level 0, משום שאבליציות ומדידות generator כבר חורגות מאינטגרציה הנדסית; אבל תוצאה מעניינת אינה paper חזק אוטומטית.

הספרות כבר כוללת סימפלקטיות נלמדת: SympNets מציג רשתות משמרות מבנה לזיהוי מערכות Hamiltonian, ו־Symplectic Neural Operators משנת 2026 עוסק במפורש ב־Hamiltonian PDEs. לכן novelty אינה יכולה להיות עצם הכנסת סימפלקטיות ל־neural operator. מסקנה זו מבוססת על המקורות הראשוניים, לא על סקירת ספרות מקיפה; הבידול האפשרי של הפרויקט הוא הבקרה על spectral excitation, ambiguity והפיצוי בין SympNets, Symplectic Neural Operators ו־generators.

המונח FNO עצמו מתייחס ללמידת אופרטורים פרמטריים במרחב Fourier; המאמר המקורי אינו מצדיק שאי יכולת של baseline מסוים ללא Δt היא אי-יכולת של המשפחה כולה. [Fourier Neural Operator](#).

H. Decisive next experiment

Experiment 1 חוק קינטי תחת תמיכה ספקטרלית ובקרה על תקציב

זהו ניסוי פקטוריאלי אחד, $\text{architecture} \times \text{spectral excitation}$, שנועד להבחין בין structural generalization, חוסר עירור, רוויה ו- $\text{capacity/optimization}$. ההשערה המוקדמת היא שקינטיקה נלמדת משותפת תקבל יתרון להעברת חוק רק אם loss מזהה אותה; אם היתרון נובע רק מהקומפקטיות או מה- baseline החלש, הוא ייעלם מול מודל קטן ותואם או לאחר הארכת אימון הוגנת.

מודלים. $C1/K0/L0$ המקורי; $C1g$ עם $\kappa(0)=0$ ואותו מספר פרמטרים; A-small מותאם לכ-2,466 סקלרים ממשיים; A-wide כבקרת capacity ו- bandwidth ; ובקרה קומפקטית בעלת אותה שיתוף-פרמטרים אבל עדכון אמפליטודה חופשי. הבקרה האחרונה נדרשת להפריד $\text{sharing/compactness}$ מן המבנה הגאומטרי. אין להכניס αk^2 feature או חוק ריבועי לפלט הראשי. $K2/\text{oracle}$ יכולים להישאר sanity checks חיצוניים, לא משתתפים בטענת law learning.

Parameter matching. סופרים סקלרים ממשיים, כולל real/imag של weights Fourier . יעד התאמה $\pm 5\%$. מימוש FNO הקיים ברוחב, שלוש שכבות ו- modes32 נותן 2,552 סקלרים לפי בנייה וספירה חדשות של המודל המקומי, ולכן הוא candidate ראשון בגבול ההתאמה; אין לו עדיין תוצאות אימון. יש לדווח שהצוואר הצר עשוי להגביל representation באופן שונה, ולהחזיק A-wide כבקרת modes32 . capacity מכסים את כל test modes המוצעים $k \leq 16$. את הבקרה הקומפקטית החופשית מכילים בגודל לפני הסתכלות ב- test .

Training distribution. רשת $N=128$ כדי להסיר את החשש המרחבי של G4 , $\text{domain}=[0, 2\pi]$, אותם α, β ומסה כמו הבסיס. שתי זרועות נתונים עם אותו מספר מסלולים וזוגות: $|k| \leq 8$ low-support ו- $|k| \leq 8$ excited-support. $k \leq 16$. בזרוע המורחבת מקצים באופן מבוקר fraction שאינו זעיר למודים 9–16, ולא מסתפקים בזנב לא-ליניארי. ההקצאה והמינימום האנרגטי נקבעים מראש. אותם IC seeds ופרמטרים paired בין architectures; איזון density/mass בין הזרועות מונע הפיכת המבחן לניסוי אמפליטודה.

Supervision. בזמן. משתמשים בצעד קצר שאינו wrapped במודים האלה, למשל $\Delta t=0.005$, או בשני צעדי זמן נפרדים לצורך בקרה אם law recovery הוא היעד; אין צורך לעורר Nyquist כדי לבחון reference 9–16. באמצעות temporal/spatial refinement, עם tolerance נמוך בהרבה מהפער הצפוי, ושמירת מטא-דאטה ומערכי בדיקה. לא משתמשים ב- oracle branch לבחירת הצלחה. אין physics loss ראשי כדי שלא למסור במישרין את החוק שמנסים לזהות.

Test distribution. ארבעה blocks שנקבעים מראש: fresh low-band IID; combinations של מודים מוכרים עם אמפליטודות/פאזות חדשות; plane waves ומצבים מעורבים עם 9–16; G3-short בצפיפות ובמסה מותאמות. ב- low-support זרוע 9–16 היא spectral extrapolation; ב- excited-support היא interpolation/new combinations. יש test נוסף של Δt שלא שימש לאימון, למשל 0.0075, דרך models התומכים ב- Δt ; ל-FNO התלוי-זמן יש להוסיף Δt כקלט ולהכלילו בהתאמת הפרמטרים אם משווים block זה. אין להעניש את A שאינו תלוי בזמן ולקבל מכך evidence.

Seeds. שישה training seeds בשני corpus splits בלתי תלויים, כלומר 12 fitted runs לכל initialization seeds של robustness על שני צירים ולא רק יותר architecture $\times$ support condition על אותו corpus. מספר fixed test ICs לכל block לפחות 100; α grid plane-wave מספיק צפוף וכל המודים מדווחים.

Budget ו-optimization. מספר updates זהה, schedule כתלות ב-batch, updates ותואם ומספר validation opportunities זהה. נותנים לכל architecture אותו budget לכיוון hyperparameters קטן על validation בלבד. הארכת אימון נרשמת מראש כחלק מהפרוטוקול אם loss עדיין משתפר; test נפתח רק אחרי הקפאת checkpoint. מדווחים גם GPU utilization, hardware, wall time, אם זמין, peak memory ו-inference throughput. בנוסף מנתחים ביצועים בנקודת זמן-אימון משותפת כדי להפריד equal-update מ-compute-matched; אין לקרוא להם אותו דבר.

Primary metric. RMSE של נגזרת הפאזה לפי α ב- $k^2 \Delta t$, normalized by 9–16, עם mean על המודים וה- α worst-intervals שנקבעו מראש. ה- $\text{architecture} \times \text{support}$ interaction הוא האומדן המכריע. מדווחים כל k וגם worst-

mode error כדי לא למצו כשל קצה. המדד נבחר לפני ההרצה, וכל plane-wave probe כולל amplitude error ו-leakage: correct phase של multiplier קטן כמעט אפס אינו prediction נכון.

Secondary metrics. complex field relative L2 aligned L2, בנפרד, error של $\alpha(k) - \alpha(0)$, trajectories coefficient/local-law residual, α -only parameter shift, spectral tail error, drift mass/H מעל 100%/10% error באופק T קבוע. reported confidence intervals נעשים ברמת training run/corpus ו-ICs, ולא ברמת time pairs; משאירים את splits והמבחנים כמקובלים.

אם הטענה המבנית נכונה. C1/C1g ינצחו גם מול A-small ובקרה קומפקטית חופשית, לא רק מול seed חלש של A; יהיה interaction עקבי של excitation על זיהוי הקינטיקה, והצלחה ב- OOD modes של low-support אם אכן קיימת extrapolation. אם C1 מצליח רק ב- excited-support , המסקנה הנכונה היא structured interpolation with identifiable data, לא spectral extrapolation. אם G3-short נשאר יתרון גם כש-law transfer נכשל, זה תוחם יתרון של לוקליות מול כשל קינטי.

אם הטענה שגויה. A-small או הבקרה הקומפקטית יהיו דומים אחרי optimization הוגן; או שכל architectures ישתפרו רק כאשר המודים נראים באימון; או C1g יתקן בעיקר offset אבל לא א גבוה. במקרה כזה פוסלים broad structural generalization, וממקדים את ההמשך במתכון קומפקטי, בגאומטריה של rollout או ב-law learning עם prior מפורש. אין לשנות את primary outcome כדי לשמור על הסיפור החיובי.

Experiment 2 gauge כיבוע בזמן האימון

זהו ניסוי משלים של identifiability, ולא עוד benchmark כללי. מאמנים C1 ו-C1g מאותו initialization של הרשת הגולמית, באותו corpus, seed, updates, workflow, עם $\lambda=0$ ובנפרד $\lambda=0.01$. משווים end-to-end accuracy, לאחר בחירת gauge משותפת, $q\delta$ והחלפות הרכיבים. צריך להראות שה-map full learned נשמר על post hoc בעוד learning path שונה. אם C1g משפר את החוק אך לא את prediction, זוהי תרומה על ייצוג/זיהוי; אם הוא רק מסיר offset שרירותי, אין claim על physics recovery. משקולות כאלה עדיין אינן קיימות בפלט של מחברת 12, ולכן תוצאה חיובית כאן תהיה ניסוי חדש באמת.

I. Research direction

ההמשך בעל הערך הגבוה ביותר הוא **spectral/kinetic identifiability**, עם C1g כפרמטריזציה מבוקרת ומדדים שאינם מערבבים פאזה, צפיפות וקצבים. יש להשאיר C1 כמכשיר מחקרי מפורש: הוא מאפשר לראות א ו- ν , לבדוק symmetry ולבצע התערבות קפואה. הגדלה מיידית ל-C2/C3 אינה פותרת את הכשל המשותף בקינטיקה K0, ותעלה משמעותית את עלות האימון לפני בידוד המנגנון.

Story A נתמך כ-compact competitive surrogate, אך parameter efficiency על Pareto frontier עדיין חסרה. Story B נתמך באופן ממוקד ב-G3-short ובהגבלת כשל נורמה, ולא ב-Story C. Story E נתמך ברמת מסה ואנרגיה באופק הנמדד, נדחה עבור high-k במשקולות הקיימות. Story D לא נבדק. Story F אין dynamics ו-cascade; אין Story F על מוגבל על ידי שגיאת cascade ו-dynamics. Story G מתאים לתצפית על bias-flexibility מול spectral shifts, אך misspecification של המשוואה עדיין דורש ניסוי מלא. Story G מתאים לכל טענת עליונות כללית כעת, אך אינו מוחק את היתרונות הממוקדים והממצא האבחוני.

כדאי לשמור parameter efficiency כשאלת משנה, עם FNO קטן ובקרת potential generalization compute; היא נקודת הצלחה שצריך לשחזר בבקרה על לוקליות. הרחבות geometric צריכות לבדוק הנחות הנכונות למשוואה: ב-gain/loss שימור מסה קשיח מטיל שגיאה בלתי נמנעת, ולכן אין להרחיב prior בלי לזהות boundary of validity. פותר exact split-step הוא ייחוס זול וטוב כשהחוק ידוע; הצדקת neural surrogate. benchmark צריכה להיות למידת רכיב חסר או נתונים מוגבלים, ולא החלפת פתרון ידוע ללא benchmark.

מפת מקורות לשחזור

תוצאות G1-G4/G6/G7/G9: Phase6_all.ipynb, במיוחד תאים 2,4,6,7,8,9; g679.ipynb הוא עותק תוצאות ולא G5 replication ושחזור: phase6_evaluation.ipynb_06, תא 4; frozen-probes/summary.json ו-kinetic-rate-bounds.json. IID rollout. phase6-training-bd4e108527-K0-standalone/metrics.json. endpoint-diagnostics.json. swaps: frozen-test/summary.json ו-learned_kinetic+exact_local.ipynb; hybrid_kinetic_ablation.ipynb; 11; 4/6 תאים 12_gauge_identifiable_c1.ipynb תאים 8/10/12 Phase7 בלבד; Downloads/metrics (1).json; Downloads/metrics.json הוא ריצת 10 אפוקים/seed0 נפרדת ולא המקור ל-Phase6 production.

קוד מפרש: `src/spno/models/split_learned.py`, `models/fno.py`, `models/base.py`; `config.py`; `data/generate.py`, `datasets.py`, `shift.py`; `train.py`; `evaluation/dispersion.py`, `spectral.py`, `.component_ablation.py`; `scripts/run_phase6.py`, `train_phase6_arms.py`, `run_hybrid_ablation.py`
קריאת קוד אינה מוכיחה שכל גרסת קוד נוכחית היא גרסת האימון המקורית; עדיפות ניתנה ל־`metadata`, `snapshot outputs` ו־`hashes` השמורים בכל ריצה.

בתיקיית הדוח נשמרו JSON, `audit_results.py`, `fresh-audit.json`, `recomputed-arm-statistics.json`, שחולץ מהמחברות, טבלאות ופלטים שחולצו, ותמונות המחברות. כדי לשחזר את החישובים החדשים: `PYTHONPATH=src .venv/bin/python results/phase6-review-2026-10-01/audit_results.py`. הסקריפט אינו מאמן, והוא מדלג במפורש על `inference` כאשר `checkpoints` אינם נמצאים; הוא אינו בונה מחדש תוצאות Colab שאינן זמינות. ביחד, הראיות נותנות שאלה מחקרית טובה: מתי מפה משמרת מבנה ודייקנית על **trajectories** לומדת **generators** נכונים, ומתי היא מסתפקת בפיצוי שאינו מעביר חוק?